

Politechnika Śląska w Gliwicach Wydział  
Automatyki,  
Elektroniki i Informatyki



## **Projekt z przedmiotu Metody Statystyczne**

### **Temat nr 18**

---

Autorzy:

Krzysztof Ból, Jonatan  
Chrobak, Łukasz  
Latusik, Witold Smaga,  
Michał Stolorz, Dawid  
Suchy, Andrzej Tenus  
Dr. inż. Marcin  
Skowronek 2018/2019  
Informatyka  
SSI  
4  
6  
2019-06-05  
2019-06-05

Prowadzący  
Rok akademicki  
Kierunek  
Rodzaj studiów  
Semestr  
Grupa  
Termin oddania sprawozdania  
Data oddania sprawozdania

---

# 1. Temat projektu

Pewien element produkowany jest w nowej i starej hali pewnego zakładu. W ramach badania wydajności pracy (w sztukach na godzinę) przy produkcji tego elementu wylosowano w każdej hali grupę pracowników i wyznaczono ich wydajność pracy. Otrzymano następujące wyniki:

W starej hali zaobserwowano następujące wydajności pracy:

36,4; 41,4; 25,7; 39,6; 40,8; 42,8; 46,4; 49,1; 47,7; 42,1; 46; 39,7; 51,7; 39,4; 39,8; 39,6; 45,2; 34,9; 41,7; 46,7; 39,8; 35; 35,8; 49,3; 42,1; 31,7; 53,3; 48,7; 47,2; 48,6; 43,9; 40,3; 39,2; 49; 44,3; 40,9; 31,7; 40,4; 22,6; 42,3; 30,3; 42,8; 54,7; 45,6; 49,8; 38,9

Wydajności pracy w nowej hali były następujące:

41,6; 43,9; 35,7; 49; 39,5; 38,9; 36,7; 29,5; 35,5; 39,3; 20,4; 37,9; 46,8; 47,8; 42,3; 42,7; 48,3; 42,7; 39,5; 48,5; 49,9; 32,9; 36,1; 45,6; 32,1; 42,7; 36,9; 59,9; 50,9; 59,5; 29,6; 50,2; 24,4; 37,8; 38,3; 39,2; 42

## 2. Rozwiązania

### Zadanie 1.

Dokonać analizy wydajności pracy przy produkcji elementu, wyznaczając miary przeciętne, zróżnicowania, asymetrii i koncentracji. Opracować histogramy rozkładów empirycznych. Miary wyznaczyć dwoma sposobami: a) na podstawie szeregu szczegółowego, b) na podstawie szeregu rozdzielczego.

### Wzory wykorzystane przy obliczaniu miar:

#### 1) Miary przeciętne

- Średnia arytmetyczna:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Średnia harmoniczna:

$$\bar{x} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

- Średnia geometryczna:

$$\bar{x} = \sqrt[n]{\prod_{i=1}^n x_i}$$

- Dominanta (Moda):

a) Dla szeregu szczegółowego:

- Wyszukanie w szeregu wartości, która występuje najczęściej.

b) Dla szeregu rozdzielczego:

- Wyszukanie tzw. przedziału dominanty (przedziału o największej liczebności), a następnie obliczenie wartości dokładnej zgodnie z wzorem:

$$D = x_0 + \frac{n_0 - n_{-1}}{(n_0 - n_{-1}) + (n_0 - n_{+1})} \cdot C_0$$

Gdzie:

$x_0$  – dolna wartość przedziału dominanty.

$n_0$  – liczebność przedziału dominanty.

$n_{-1}$  – liczebność przedziału poprzedzającego przedział dominanty.

$n_{+1}$  – liczebność przedziału następującego po przedziale dominanty.

$C_0$  – rozpiętość przedziału dominanty.

Obliczenie dominaty zostało zaimplementowane w funkcjach „dominantaSzczegolowy” oraz „dominantaRozdzielczy”.

## 2) Miary zróżnicowania

- Rozstęp wyników:

$$Q_3 - Q_1$$

- Rozstęp międzykwartkowy:

$$Q = \frac{Q_3 - Q_1}{2}$$

- Wariancja próbkowa:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Odchylenie standardowe:

$$S = \sqrt{S^2}$$

- Odchylenie od średniej (odchylenie przeciętne):

a) Dla szeregu szczegółowego:

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

b) Dla szeregu rozdzielczego:

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \cdot n_i$$

- Odchylenie od mediany (odchylenie ćwiartkowe):

$$Q = \frac{(Q_3 - Me) + (Me - Q_1)}{2} = \frac{Q_3 - Q_1}{2}$$

- Współczynnik zmienności:

$$V = \frac{S}{\bar{x}}$$

### 3) Miary asymetrii i koncentracji

- Skośność:

$$As = \frac{1}{n} \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{S^3}$$

- Kurtoza:

$$Krt = \frac{1}{n} \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{S^4}$$

- Excess:

$$Ex = Krt - 3$$

Ponadto do obliczenia kwantyla rzędu n dla szeregu rozdzielczego została napisana funkcja zgodnie z poniższym wzorem.

$$Q = x_{i_0} + \frac{(poz.Q - n_{isk-1}) \cdot c_{i_0}}{n_{i_0}},$$

Gdzie:

$x_{i_0}$  – dolna wartość przedziału kwantyla.

poz.Q – pozycja kwantyla.

$n_{isk-1}$  – liczebność skumulowana przedziału poprzedzającego przedział kwantyla.

$c_{i_0}$  – rozpiętość przedziału kwantyla.

$n_{i_0}$  – liczebność przedziału kwantyla.

**Wyniki uzyskane dla szeregu szczegółowego.**

	<b>Stara hala</b>	<b>Nowa hala</b>
--	-----------------------	------------------

Średnia arytmetyczna:	41.87916 67	40.93243243
Średnia harmoniczna:	40.65065 51	39.05881322
Średnia geometryczna:	41.30548 63	40.04055569
Kwartyl 0.25:	39.55	36.7
Kwartyl 0.75:	46.475	46.8
Mediana:	41.9	39.5
Dominanta:	brak	42.7
Rozstęp wyników:	32.1	39.5
Rozstęp międzykwartkowy:	6.925	10.1
Wariancja obciążona:	42.88289 93	68.17948868
Wariancja nieobciążona	43.79530 14	70.07336336
Odchylenie standardowe:	6.617801 9	8.37098342
Odchylenie od średniej:	4.920833 3	6.35222790
Odchylenie od mediany:	3.462500 0	5.05000000
Współczynnik zmienności:	0.158021 3	0.20450735
Skośność:	- 0.624571 7	-0.01035532
Kurtoza:	3.548253 2	3.22403071
Excess:	0.548253 2	0.22403071

### Wyniki dla szeregu rozdzielczego.

	<b>Stara hala</b>	<b>Nowa hala</b>
Średnia arytmetyczna:	41.66666 67	40.608108 1
Średnia harmoniczna:	40.50328 21	38.752649 0
Średnia geometryczna:	41.12004 81	39.722703 9
Kwartyl 0.25:	36.47058 82	35.855263 2
Kwartyl 0.75:	45.44444 44	45.151515 2
Mediana:	41.09375	38.157894 7
Dominanta:	43.57142	38.235294

	86	1
Rozstęp wyników:	35	40
Rozstęp międzykwartkowy:	8.9738562	9.4098884
Wariancja obciążona:	40.9722222	66.6910153
Wariancja nieobciążona	41.8439716	68.5435435
Odchylenie standardowe:	6.4009548	8.1664567
Odchylenie od średniej:	5.0347222	6.4353543
Odchylenie od mediany:	4.4869281	4.7049442
Współczynnik zmienności:	0.1536229	0.2011041
Skośność:	-0.6399116	-0.1237806
Kurtoza:	3.3498995	3.05447
Excess:	0.3498995	0.0544700


## Histogramy:

### Zadanie


Sprawa normalna (0,95).

### Histogram wydajności pracy w starej hali

zkład ności



### Histogram wydajności pracy w nowej hali



Tablica rozkładu wartości dla testu Kołmogorowa-Smirnowa z poprawką Lillieforsa:

n	poziom $\alpha$	
	0,01	0,05
31	0,1852	0,1591
32	0,1823	0,1566
33	0,1795	0,1542
34	0,1768	0,1519
35	0,1743	0,1498
36	0,1717	0,1477
37	0,1695	<b>0,145</b>
38	0,1673	0,1437
39	0,1651	0,1419
40	0,163	0,1401
41	0,161	0,1384
42	0,1591	0,1367
43	0,1572	0,1351
44	0,1554	0,1336
45	0,1537	0,1321
46	0,152	0,1306
47	0,1504	0,1292
48	0,1488	<b>0,127</b>
49	0,1473	0,1266
50	0,1458	0,1253
51	0,1444	0,1241
52	0,143	0,1229
53	0,1416	0,1217
54	0,1403	0,1206
55	0,139	0,1193
60	0,1331	0,1144
65	0,1279	0,1099
70	0,1232	0,1059
75	0,119	0,1023
80	0,1153	0,0991
85	0,1118	0,0961
90	0,1087	0,0934
95	0,1058	0,0909
100	0,1031	0,0886

Korzystając z poniższych wzorów obliczamy wartość D:

$$D = \max D^{+i, D^{-i, i}}$$



$$D^{+} = \max_{i=1, \dots, n} \frac{i}{n} - p(i) \hat{\sigma}$$

$$D^{-} = \max_{i=1, \dots, n} p(i) - \frac{(i-1)}{n} \hat{\sigma}$$

$p(i)$  – funkcja rozkładu normalnego

Porównujemy otrzymane wartości D z wartościami k uzyskanymi z tabeli – pogrubione, w czerwonych ramkach.  
Wynik działania programu:

```
Dane 1 (stara hala):
wartosc D wynosi: 0.1387923
wartosc k wynosi: 0.1279
wydajnosci pracy nie maja rozkladu normalnego.
Dane 2 (nowa hala):
wartosc D wynosi: 0.09601999
wartosc k wynosi: 0.1457
wydajnosci pracy maja rozklad normalny.
```

### Zadanie 3.

Oszacować przedziałowo (współczynnik ufności 95) wartość przeciętną wydajności pracy produkcji elementu w starej hali. Obliczyć względną precyzję oszacowania i sprawdzić, czy mamy podstawy do uogólnienia otrzymanego przedziału ufności na całą populację wydajności pracy przy produkcji elementu w starej hali.

Ponieważ odchylenie standardowe dla całej populacji jest nieznane skorzystamy z następującego wzoru na estymację przedziałową:

$$P\left(\bar{x} - t_{\alpha, n-1} \frac{s}{\sqrt{n}} < \mu < \bar{x} + t_{\alpha, n-1} \frac{s}{\sqrt{n}}\right) = 1 - \alpha,$$

gdzie  $t_{\alpha, n-1}$  jest wartością z tablic t-Studenta dla  $n-1$  stopni swobody, spełniającą warunek  $P(|t| < t_{\alpha, n-1}) = 1 - \alpha$ .

Obliczamy potrzebne wartości za pomocą funkcji:

- `sd(stara)` – aby otrzymać próbkowe oszacowanie odchylenia standardowego
- `qt(0.975, n-1)` – aby otrzymać wartość z tablic t-Studenta dla współczynnika ufności równego 95% przy  $n-1$  stopniach swobody
- `mean(stara)` – aby otrzymać średnią wszystkich wartości zawartych w podanych danych

Następnie, aby obliczyć względną precyzję naszego przybliżenia, korzystamy ze wzoru:

$$\delta = \frac{d}{\bar{x}} * 100\%,$$

Gdzie:

d - bezwzględny błąd szacunku.

Wynik działania programu:

```
> zad3(stara)
[1] "interwał estymacji przedziałowej o dokładności 95%:"
[1] 39.9576 43.8008
[1] "względna precyzja oszacowania:"
[1] 4.5885
```

Ponieważ względna precyzja estymacji przedziałowej jest mniejsza od 5%, uprawnione jest uogólnienie wyniku na całą populację.

#### Zadanie 4.

Oszacować przedziałowo (współczynnik ufności 95) odchylenie standardowe wydajności pracy produkcji elementu w nowej hali. Obliczyć względną precyzję oszacowania i sprawdzić, czy mamy podstawy do uogólnienia otrzymanego przedziału ufności na całą populację wydajności pracy przy produkcji elementu w starej hali.

Średnia próby:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Wariancja próbkowa:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Odchylenie standardowe:

$$S = \sqrt{S^2}$$

Przedział ufności:

$$P\left\{\bar{x} - \frac{u_{\alpha} S}{\sqrt{n}} < m < \bar{x} + \frac{u_{\alpha} S}{\sqrt{n}}\right\} = 1 - \alpha$$

Gdzie dla  $1 - \alpha = 0.95$  :  $u_{\alpha} = 1.96$

Względna precyzja oszacowania:

$$\delta = \frac{d}{\bar{x}} * 100\%$$

Obliczamy potrzebne wartości za pomocą funkcji:

- `sd(nowa)` - aby otrzymać próbkowe oszacowanie odchylenia standardowego
- `qt(0.975,n-1)` - aby otrzymać wartość z tablic t-Studenta dla współczynnika ufności równego 95% przy  $n-1$  stopniach swobody
- `mu(nowa)` - aby otrzymać średnią wszystkich wartości zawartych w podanych danych

Przy pomocy funkcji `sigma<-sd(nowa)` wyznaczamy odchylenie standardowe.

Następnie przechodzimy do wyznaczenia interwału estymacji przedziałowej o dokładności 95%.

Robimy to przy pomocy funkcji:

`round(mu+c(-1,1)*sigma/sqrt(n)*qnorm(.975),2)`

Oraz względną precyzję oszacowania:

`interval=mu+c(-d,d)`

Wynik działania programu:

```
> zad4(nowa)
[1] "Interwał, estymacji przedziałowej o dokładności 95%:"
[1] 38.1414 43.7235
[1] "względna precyzja oszacowania:"
[1] 6.8186
```

Ponieważ względna precyzja estymacji przedziałowej jest większa od 5% nie możemy uogólnić wyniku na całą populację.

### **Zadanie 5.**

Czy na poziomie istotności 0,05 można twierdzić, że wartości wydajności pracy przy produkcji elementu w starej hali są większe (sformułować i zweryfikować odpowiednią hipotezę)?

Zaczynamy od wykonania testu Fishera w celu przetestowania czy wariancje rozkładów zmiennych losowych dla starej i nowej hali są sobie równe. W zależności od wyniku dobieramy odpowiedni test dla wartości oczekiwanej.

### **Test Fishera został przeprowadzony według wzoru:**

Statystyka testowa F:

$$F = \frac{S_2^2}{S_1^2}$$

gdzie:  $S_{i2}^2$ ,  $S_{i1}^2$  – nieobciążone estymatory wariancji z populacji

zakładamy, że  $S_{i2}^2 > S_{i1}^2$

Obszar krytyczny testu Fishera:

$$K_0 = (f(0.95, n_1 - 1, n_2 - 1), +\infty)$$

gdzie:  $f(0.95, n_1 - 1, n_2 - 1)$  – kwantyl rzędu 0.95 rozkładu F ze stopniami swobody  $n_1 - 1$  oraz  $n_2 - 1$

#### TEST FISHERA

H0: Wariancje wydajności pracy są sobie równe

H1: Wariancje wydajności pracy są różne od siebie

Statystyka testowa  $F = 0.6249921$

Obszar krytyczny  $K_0 = (0.5435032; 1.839916)$

Wartość statystyki zawiera się w obszarze krytycznym.

Odrzucamy hipotezę zerową na rzecz hipotezy alternatywnej.

Na poziomie istotności 0.05 można przyjąć hipotezę alternatywną.

Na podstawie testu Fishera nie odrzucamy hipotezy zerowej mówiącej, że wariancje wydajności pracy w starej i nowej hali są sobie równe. Przyjmujemy, że wariancje są takie same zatem do testowania hipotezy o wartościach oczekiwanych stosujemy test T – Studenta.

#### Test T-Studenta został przeprowadzony według wzoru:

$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{n_1 S_1^2 + n_2 S_2^2}{n_1 + n_2 - 2} \left( \frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

gdzie  $S_1^2$  i  $S_2^2$  są nieobciążonymi estymatorami wariancji.

Natomiast obszar krytyczny jest postaci:

$$K_0 = \left( -\infty, -t \left( 1 - \frac{\alpha}{2}, n_1 + n_2 - 2 \right) \right) \cup \left( t \left( 1 - \frac{\alpha}{2}, n_1 + n_2 - 2 \right), +\infty \right)$$

Gdzie  $t$  to kwantyl rzędu 0.95 rozkładu T ze stopniem swobody  $n_1 + n_2 - 2$

Weryfikujemy hipotezę H0: Średnie wydajności pracy w obu halach są sobie równe, przeciw hipotezie H1: Średnia wydajność pracy w starej hali jest większa.

#### TEST T-STUDENTA

H0: Średnia wydajność pracy w hali starej i nowej jest taka sama

H1: Średnia wydajność pracy w hali starej jest większa

Statystyka = 0.5753955

Obszar krytyczny  $K_0 = (-1.66342; +\infty)$

Wartość statystyki NIE mieści się w obszarze krytycznym.

Brak podstaw do odrzucenia hipotezy zerowej.

Zatem nie można stwierdzić, że wydajność pracy w starej hali jest większa niż w nowej.

Alternatywą dla testu T-Studenta jest test Cochran-Coxa. Stosujemy go, gdy w teście Fishera wartość statystyki nie zawiera się w obszarze krytycznym. Jest on określony wzorem:

$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

gdzie  $S_1^2$  i  $S_2^2$  są nieobciążonymi estymatorami wariancji.

Natomiast obszar krytyczny jest postaci:

$$K_0 = (-\infty, -t] \cup [t, \infty)$$

Gdzie  $t$  to kwantyl rzędu 0.95 rozkładu T ze stopniem swobody  $v$  wyliczanym ze wzoru:

$$v = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{1}{n_1+1} \left(\frac{S_1^2}{n_1}\right)^2 + \frac{1}{n_2+1} \left(\frac{S_2^2}{n_2}\right)^2}$$

Źródła:  
 „Wykłady z Metod Statystycznych dla Informatyków z przykładami w języku R”  
 Katarzyna Stąpor, Wydawnictwo Politechniki Śląskiej  
 „Przewodnik po pakiecie R”  
 Przemysław Biecek, Oficyna Wydawnicza GiS  
[www.rdocumentation.org](http://www.rdocumentation.org)